인과관계 추론 중간과제

- 학번: 202457-352014
- 이름: 신승엽
- 학과: 첨단공학부 AI전공
- 연락처: 010-4195-1949

1. 인과관계와 상관관계에 대해 다음 질문에 답하시오.

1) 인과관계의 정의를 간단히 작성하시오.

인과관계란 하나의 사건이 다른 사건을 직접적으로 발생시키는 관계를 말한다. 원인 변수 X가 변할 때 그 결과로 Y도 변하는 경우이며, "X가 Y를 일으킨다"라고 표현한다.

2) 상관관계의 정의를 간단히 작성하시오.

상관관계란 두 변수가 함께 변하는 통계적 경향이 있는 관계이다. 한 변수가 증가할 때 다른 변수도 같이 증가하거나 감소하는 패턴이 보이는 것인데, 이것만으로는 둘 사이에 인과관계가 있다고 말할 수 없다.

3) 실제로는 상관관계인데, 인과관계로 착각하는 예시에 대해 약술하시오(최소 5문장 이상)

소방차 출동 횟수와 화재 피해액 사이의 관계가 대표적인 예시이다. 데이터를 보면 소방차가 많이 출동한 화재일수록 피해액이 크게 나타난다. 이것만 보면 "소방차를 많이 보내면 피해가 커진다"는 결론을 내릴 수도 있다. 하지만 실제로는 화재 규모라는 제3의 변수가 있다. 불이 크게 나면 소방차도 많이 출동하고, 피해액도 당연히 커지는 것이다. 소방차 출동이 피해를 키운 게 아니라, 화재 규모라는 공통 원인이 두 변수를 동시에 움직인 것이다. 이런 식으로 교란변수를 무시하고 상관관계만 보면 잘못된 인과적 해석을 하게 되므로, 인과 추론을 하려면 통제 변수 분석이나 실험 설계 같은 방법이 필요하다.

2. 확률과 기대값

1) 조건부확률의 정의를 약술하시오.

조건부확률이란 어떤 사건 B가 이미 일어났다는 전제 하에 사건 A가 발생할 확률이다. $P(A|B) = P(A \cap B) / P(B)$로 계산하며, $P(B) > 0$이어야 한다. 전체 표본공간을 B가 발생한 경우로 좁힌 다음, 그 안에서 A의 확률을 구하는 것이라

고 이해하면 된다.

2) 6면체 주사위를 한번 던져서 나온 눈금의 기대값을 계산하시오.

$$E(X) = \sum_{i=1}^{6} x_i \cdot P(x_i) = 1 \cdot \frac{1}{6} + 2 \cdot \frac{1}{6} + 3 \cdot \frac{1}{6} + 4 \cdot \frac{1}{6} + 5 \cdot \frac{1}{6} + 6 \cdot \frac{1}{6} = \frac{21}{6} = 3.5$$

3) 6면체 주사위를 두 번 던질 때 나올 숫자의 표본공간은 무엇인가?

두 번 던지는 경우의 표본공간 S는 순서쌍 (i, j)의 집합이다 (i, j = 1, 2, 3, 4, 5, 6).

S = {(1,1), (1,2), (1,3), ..., (1,6), (2,1), (2,2), ..., (6,5), (6,6)}

총 원소의 수: 6 × 6 = 36개

4) 6면체 주사위를 두 번 던질 때의 기댓값을 계산하시오.

두 주사위의 눈금의 합을 X + Y라 하면, 기대값의 선형성에 의해:

$$E(X+Y) = E(X) + E(Y) = 3.5 + 3.5 = 7$$

5) 6면체 주사위를 두 번 던질 때의 기댓값과 분산을 구하기 위한 R 코드를 각각 작성하시오.

기댓값 R 코드:

```r
# 두 주사위의 합에 대한 기댓값
dice1 <- 1:6
dice2 <- 1:6
outcomes <- expand.grid(dice1 = dice1, dice2 = dice2)
outcomes$sum <- outcomes$dice1 + outcomes$dice2
expected_value <- mean(outcomes$sum)
cat("기댓값:", expected_value, "\n")
```

분산 R 코드:

```r
# 두 주사위의 합에 대한 분산
variance <- var(outcomes$sum) * (nrow(outcomes) - 1) / nrow(outcomes)
cat("분산:", variance, "\n")
```

6) 6면체 주사위를 한 번 던졌을 때 1이 나왔다고 하자. 이 때, 두 번째 던졌을 때 6이 나올 확률은 얼마인가?

두 번의 주사위 던지기는 독립 사건이므로, 첫 번째 결과가 두 번째 결과에 영향을 미치지 않는다.

$$P(\text{두 번째} = 6 \mid \text{첫 번째} = 1) = P(\text{두 번째} = 6) = \frac{1}{6}$$

따라서 확률은 1/6이다.

3. OLS 회귀분석

기업에서 최소자승법(OLS)을 사용하여 어떤 데이터 세트에 대한 선형 회귀모델을 구축하고자 한다. 독립변수 X는 광고비용(단위: 만 원), 종속변수 Y는 판매량(단위: 천 개)이다. 초기 데이터 분석 결과, 광고비용이 증가함에 따라 판매량도 증가하는 경향이 관찰되었다.

1) 광고비용이 판매량에 미치는 영향에 대해 분석하고자 한다. 이 때, 추가적으로 가지고 있는 자료가 상품의 가격(P, 단위: 만 원)이라고 하자. 가격이 판매량에 영향을 미친다고 할 때, 이 분석을 위한 DAG를 간단하게 작성하시오.

- 광고비용(X) → 판매량(Y)
- 가격(P) → 판매량(Y)

광고비용과 가격 두 변수 모두 판매량에 영향을 주는 구조이다. 광고를 많이 하면 판매량이 증가하고, 가격이 높아지면 판매량이 감소하는 방향이다. 광고비용(X)과 가격(P) 사이에는 직접적인 인과관계가 없다고 가정한다.

2) R을 이용하여 회귀분석 결과가 다음 표와 같이 나왔다고 하자. 통계적인 관점에서, 판매량에 영향을 준 요인은 어떤 변수인가?

변수	Estimate	Std.Error	t-value	p-value
(Intercept)	-0.0683	4.863	-0.01	0.98
가격	-0.7858	0.199	-3.94	0.00
광고비용	0.0999	0.097	1.02	0.31

통계적 유의수준 α = 0.05 기준으로, 가격 변수의 p-value가 0.00으로 유의수준보다 작으므로 통계적으로 유의하다. 반면 광고비용의 p-value는 0.31로 유의수준보다 크므로 통계적으로 유의하지 않다.

따라서 통계적 관점에서 판매량에 유의미한 영향을 준 요인은 가격(P)이다.

3) 가격이 1만 원 상승할 때, 판매량은 몇 개가 줄어드는가?

가격의 회귀계수(Estimate)가 -0.7858이고, 판매량의 단위가 천 개이므로:

가격이 1만 원 상승하면, 판매량은 약 0.7858천 개, 즉 약 786개 줄어든다.

4) 위의 모형을 개선하기 위해 할 수 있는 방안에 대해 간단하게 서술하라.(최소 3줄 이상)

우선 광고비용이 유의하지 않게 나온 원인을 확인해볼 필요가 있다. 가격과 광고비용 사이에 다중공선성이 있을 수 있으므로 VIF를 계산해서 점검해보고, 문제가 있으면 변수를 제거하거나 주성분 회귀 등을 시도해볼 수 있다.

또한 현재 모형에는 가격과 광고비용 두 변수만 들어가 있는데, 판매량에 영향을 줄 수 있는 다른 변수들(계절, 프로모션 여부, 유통 채널 등)이 빠져 있을 수 있다. 이런 변수를 추가하면 누락변수로 인한 편향을 줄이고 모형의 설명력을 높일 수 있을 것이다.

그리고 잔차 분석을 통해 선형 관계 가정이 맞는지도 확인해봐야 한다. 잔차 그래프에서 비선형 패턴이 보인다면 로그 변환이나 다항회귀 같은 방법을 적용해보는 것도 방법이다.